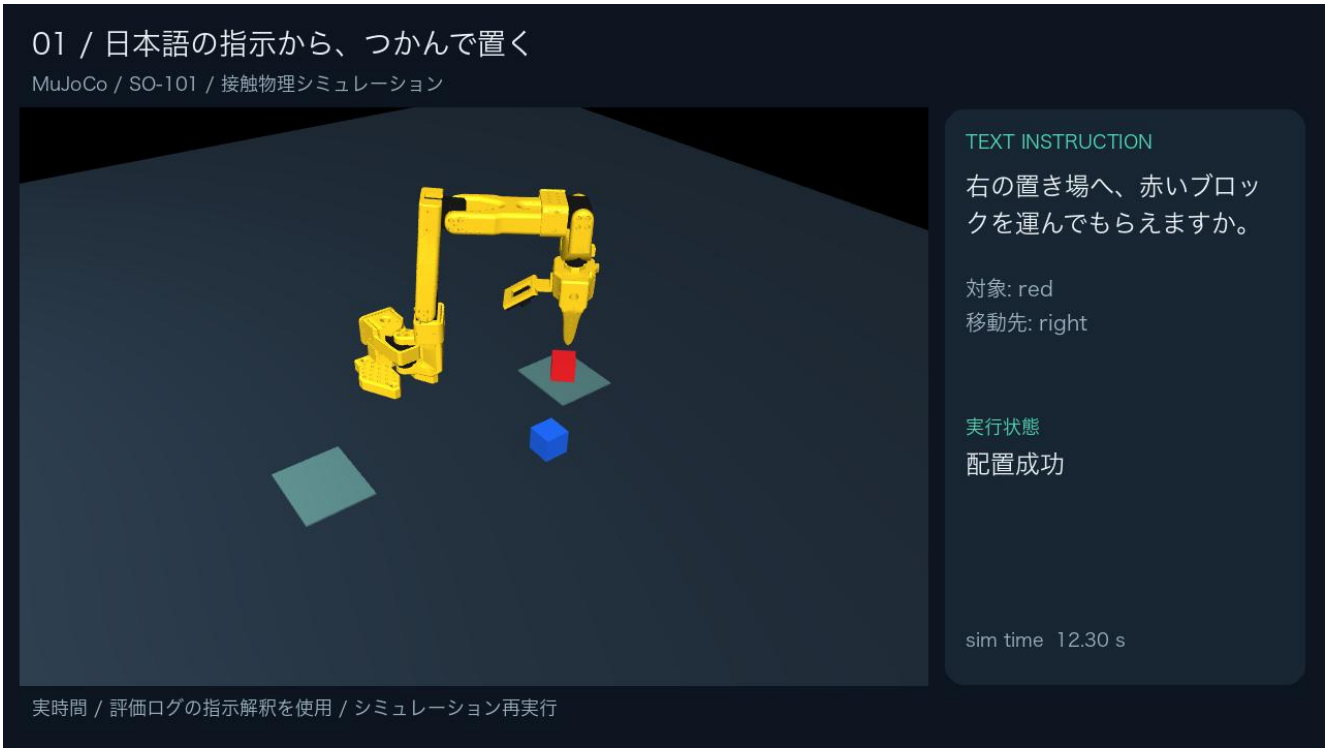
言葉が通じても、 つかめるとは限らない

SO-101による日本語指示・物理操作・失敗回復の検証

Physical AI 応用編1 最終課題 / 2026年11月1日



1. 目的と問い

個人でも導入を検討できる小型アームを、工作・軽作業の卓上アシスタントとして使いたい。そこで「色付きブロックを指定の置き場へ運ぶ」作業を題材に、言葉の意味を理解することと、物理的な作業を完了することの違いを調べた。

問いは、①否定や言い直しを含む指示を解釈できるか、②対象が曖昧・不在・到達不能な場合に実行を見送れるか、③つかみ損ねに気づいて再試行すると成功率が改善するか、の3点である。

AIと制御の役割

AIはQwen3-4B-Instruct-2507の4bit版によるテキスト推論。出力は対象色・行き先・操作のJSON。物体の存在確認、逆運動学、関節位置制御、成功判定は明示的なプログラムである。モデル学習・音声認識・画像認識は実施していない。

実装と再現できる評価

2. システム構成

日本語テキスト → ローカルLLM → 構造化指示 → 対象の一意性・到達可能性を確認 → 逆運動学 → 関節目標角 → MuJoCoの接触・重力・摩擦 → 結果を記録。

SO-101の公開MJCFとメッシュを使用し、関節可動域・アクチュエータの力制限は公開モデルの値を維持した。物体を持ち上げるための固定拘束や、実行中に物体位置を書き換える操作はない。対象の色と座標はシミュレータ内部情報を使用する。左右の置き場は平面の目標領域であり、実物の箱ではない。

最初の高い持ち上げ軌道は、下向きの指先姿勢を保ったまま到達できなかった。作業範囲を絞り、移動時の指先高さを7.5cmに変更した。開発用の20試行で把持・配置を確認してから評価へ進んだ。

3. 評価設計

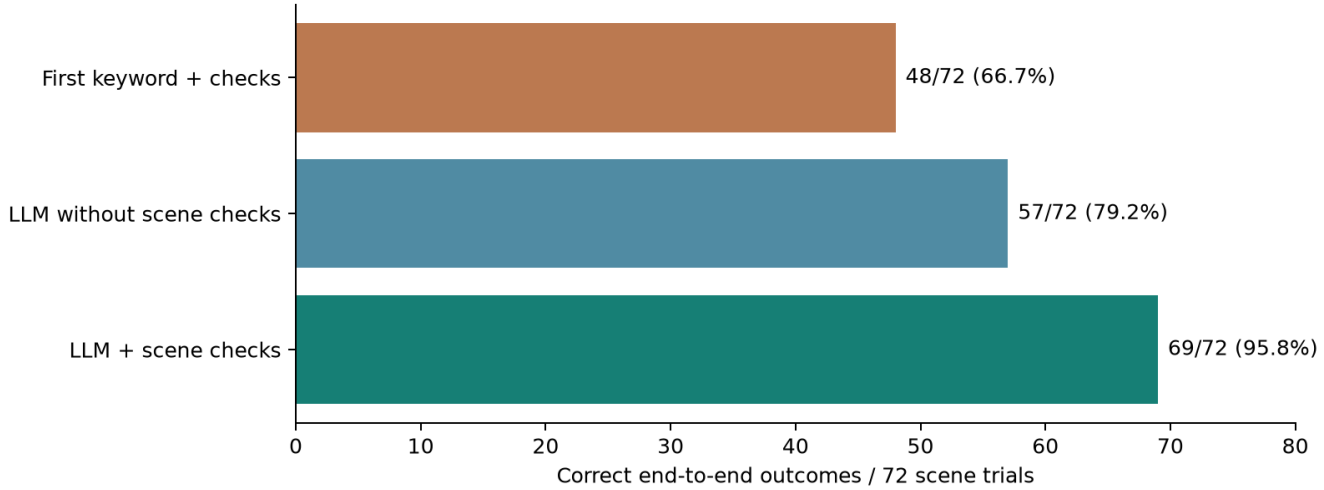
項目	条件
言語・操作評価	24指示（実行12、確認・拒否12）×配置seed 10/11/12 ×3方式 = 216試行
比較方式	最初の色・方向の単語 + 確認 / LLM + 確認なし / LLM + 確認あり
失敗回復評価	誤差0または35mm ×再試行なし/あり ×2色×2行き先×3seed = 48試行
物理成功	対象が高さ4.5cmを超えて持ち上がり、最後に目標中心から3.5cm以内かつ高さ4cm未満
再現性	モデルrevision、依存版、プロンプトとデータのハッシュ、各試行の出力・座標・seedを保存

配置の乱数は初期位置の各軸±8mm。LLMは24指示を各1回推論し、同じ結果を3配置と比較方式で共有した。72試行は72種類の独立した日本語例ではない。開発用6指示で設定を調整した後、評価用24指示では変更していない。

実行環境・RoboOps

Apple M3 / 16GB、Python 3.12、MuJoCo 3.2.7、MLX-LM 0.32.2。無料のローカル推論を使用した。第2回の「管理・検証・自動化」を、条件固定・失敗例の保存・評価スクリプト・自動テストに反映した。音声認識を外すことで、聞き間違いと操作失敗を切り分けた。

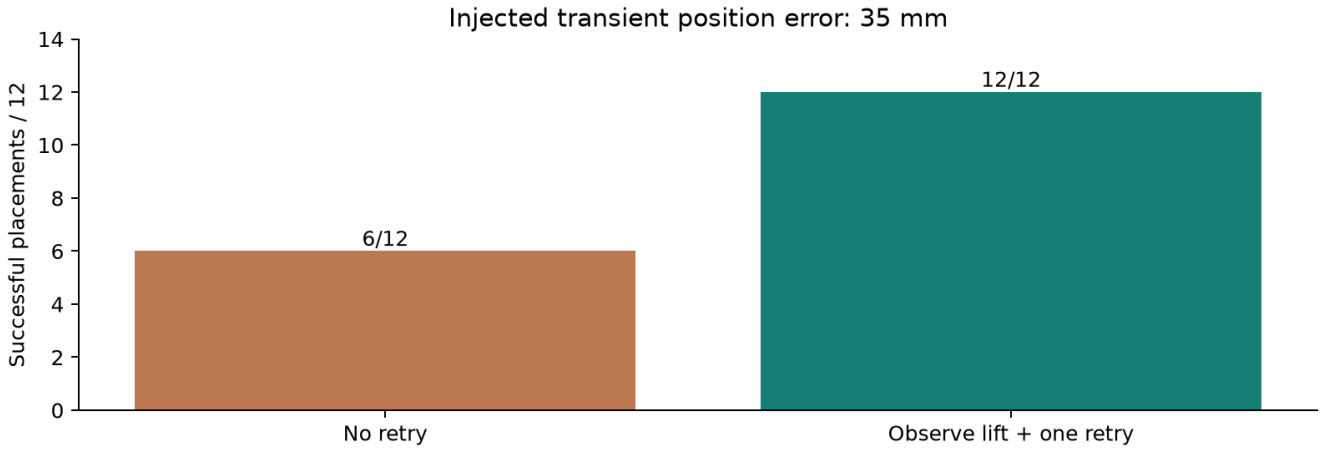
結果：理解・確認・物理を分ける



方式	正常な作業を完了	確認・拒否が適切	不要な実行開始
単語＋確認	21/36	27/36	9
LLM・確認なし	36/36	21/36	12
LLM＋確認	36/36	33/36	0

単語方式は否定・訂正を含む5指示で対象や行き先を誤った。LLMは実行可能な12指示を正しく解釈したが、確認なしでは同色2個から勝手に選ぶ、届かない物への実行を試みるという問題が生じた。到達不能では逆運動学で停止し、実際の腕の移動には進んでいない。

LLM＋確認は69/72が期待どおりだったが、失敗も残った。「ブロックを左へ」の色未指定に対し、モデルがmove・color=nullを出し、後段が確認要求ではなく不存在として拒否した（T17、3配置）。不完全出力を動作へ通さなかった点と、対話として正しく確認できなかった点を区別する。



初回の把持目標に35mmの誤差を入れると、再試行なしは6/12成功。持ち上げを確認し、一度再観測してやり直すと12/12となった。誤差なしは両方式12/12。誤差ありの平均シミュレーション時間は11.8秒から14.8秒へ増えた。

考察・限界・再現方法

4. 何が分かったか

言語モデルの理解力と、ロボットに実行させてよいかの判断は別の問題である。また、正しく対象を選んでも、位置誤差があればつかめない。言語・実行前確認・物理結果のログを分けることで、改善すべき場所を特定できた。

開発時には英語のシステム指示で「青ではなく赤」を青と解釈した。日本語の規則と開発例を追加すると改善した。変更前の出力も保存しており、結果だけでなく試行錯誤を確認できる。

LLM推論時間は24指示で中央値5.82秒、範囲3.32〜8.59秒（初回を含む、モデル読込は除外）。この値はテキスト解釈の処理時間であり、音声遅延や実機応答時間ではない。今回、遅延を変化させる比較実験は行っていない。

5. 結果の限界

小規模な人工指示セットと2個の同形ブロックを使う限定的な実験である。成功率を日本語全般・未知物体・実機の能力へ一般化できない。単語方式は意図的に単純な比較対象であり、すべてのルールベース手法より優れることを示していない。

再試行では2回目に正しい位置が得られる。継続する校正誤差やカメラの遮蔽には対応していない。実機、実カメラ、音声、産業現場の安全性は未検証。持ち上げ判定にもシミュレータの真の物体高さを用いている。色未指定の確認処理と、現実の観測誤差を含む評価は今後の課題である。

6. 再現とAI支援

README の手順で環境を作り、demo.pyで新しい指示を入力できる。run_evaluation.pyで言語・物理評価、run_recovery.pyで誤差比較を再実行する。記録済み推論を利用する場合は、推論の再実行とは区別する。GitHubにコード、評価入力、モデル出力、数値ログ、出典を公開する。

テーマ・用途・制約は受講者が設定し、実装・評価の自動化・資料作成にはCodexの支援を用いた。講義資料自体は公開物へ含めていない。

出典・公開コード

SO-101モデル: github.com/google-deepmind/mujoco_menagerie（commit b0655057…、Apache-2.0）

言語モデル: huggingface.co/mlx-community/Qwen3-4B-Instruct-2507-4bit（revision 50d42775…）

推論: github.com/ml-explore/mlx-lm / シミュレータ: mujoco.org

参考: anthropic.com/research/claude-plays-robotics（操作方法を分けて評価する発想）

成果物: github.com/Aryu-Tamura/physical-ai-so101-language